

Autoencoder regularizado

$$\text{codificador} = x \rightarrow z$$

$$\text{decodificador} = z \rightarrow \hat{x}$$

Modelo:

$$z = f(x; W_1, b_1) = \phi(W_1 x + b_1)$$

W_1 = matriz de pesos del codificador

b_1 = es el vector de sesgos del codificador

ϕ = función de activación

z = espacio latente

$$\hat{x} = g(z; W_2, b_2) = \psi(W_2 z + b_2)$$

W_2 = Matriz de pesos del decodificador

b_2 = vector de sesgos del decodificador

ψ = función de activación

\hat{x} = reconstrucción de la entrada

Función de costo:

$$E_x \{ L(x, \hat{x}) \} + \lambda(w)$$

λ = Regularizador

Function de optimization

$$\hat{\theta} = \operatorname{argmin}_{\theta} \mathbb{E}_{\mathcal{X}} \{ \mathcal{L}(\mathcal{X}, \hat{\mathcal{X}}) + \lambda(\omega) \}$$

$$\hat{\theta} = \operatorname{argmin}_{\theta} \sum_N \sum_D \mathcal{X}_{ND} \log(\hat{\mathcal{X}}_{ND}) + \lambda \|\omega\|_2^2$$

Autoencoder

Variational

Modelo:

$$z = f(\mathcal{X}; \omega_1, b_1) = \phi(\omega_1 \mathcal{X} + b_1)$$

$$\hat{\mathcal{X}} = g(z; \omega_2, b_2) = \psi(\omega_2 z + b_2)$$

$$p(z | \mathcal{X}, \theta) \text{ Prior}$$

$$q_{\theta}(z | \mathcal{X}) \text{ Posterior}$$

$$p(z) \sim \mathcal{N}(z; 0, I)$$

$$\text{En el encoder} \Rightarrow q_{\theta}(z | \mathcal{X}) = \mathcal{N}(z; \mu(\mathcal{X}), \sigma^2(\mathcal{X})I)$$

$$\Rightarrow z = \mu(\mathcal{X}) + \sigma(\mathcal{X}) \odot \mathcal{N}(0, I)$$

$$\text{En el decoder: } p(\mathcal{X} | z) = \mathcal{N}(\mathcal{X}; \mu(z), \sigma^2(z)I)$$

function de costo

$$KL(q(z | \mathcal{X}; \theta) || p(z | \mathcal{X}; \theta)) + \mathcal{L}(\mathcal{X}, \hat{\mathcal{X}})$$

$$= \text{KL}(q(z|x) || p(z)) - \mathbb{E}_z [\log p(x|z)] + \log p(x) + \mathcal{L}(x, \hat{x})$$

función de optimización

$$\hat{\Theta} = \underset{\Theta}{\operatorname{argmin}} \mathcal{L}(x, \hat{x}) + \text{KL}(q(z|x, \Theta) || p(z)) - \mathbb{E}_z [\log p(x|z)]$$

Redes generativas

adversarias (GAN)

Modelo

Generador

$$x \in \mathbb{R}^D$$

$$\hat{x} \in \mathbb{R}^{D \times D_1}$$

$$\Rightarrow \hat{x} = \Phi(W_1 x + b_1)$$

$$\Theta_1 = W_1, b_1$$

Aquí se espera
que \hat{x} siga un
prior $p_h(H)$

Discriminador

$$\hat{x} \in \mathbb{R}^{D \times D_1}$$

$$\gamma \in [0, 1]$$

$$\Rightarrow \gamma = \Psi(\hat{x}, \Theta_2) = \Psi(W_2 \hat{x} + b_2)$$

$$\gamma = \begin{cases} 1 & \text{si } x \in \mathcal{X} \\ 0 & \text{si } x \in \hat{\mathcal{X}} \end{cases}$$

función de costo

$$\mathcal{L}_S = -\mathbb{E}_{H \sim p_{\text{CH}}} [\log \gamma(\hat{x}(H))]$$

$$\begin{aligned} \mathcal{L}_d &= -\mathbb{E}_{x \sim \text{real}} [\log(\gamma(x))] \\ &\quad - \mathbb{E}_{x \sim p(x)} [1 - \log(\gamma(\hat{x}(x)))] \end{aligned}$$

función de optimización

$$\hat{\theta}_1, \hat{\theta}_2 = \min_{\theta_1} \max_{\theta_2} \mathcal{L}_d(\theta_2) - \mathcal{L}_g(\theta_1)$$