

# Reconocimiento de emociones a partir de señales de EEG



Julian Andres Salazar Parias  
Andrés Marino Álvarez Meza, Ph.D.  
Yeison Norberto Cardona Álvarez, MSc.  
Universidad Nacional de Colombia  
Control y Procesamiento Digital de Señales - GCPDS

8 de octubre de 2024



# Contenido

1 Motivacion

2 Problema

3 Estado del arte

4 Objetivos

5 Experimentos

6 Conclusiones

7 Referencias



# Contenido

1 Motivacion

2 Problema

3 Estado del arte

4 Objetivos

5 Experimentos

6 Conclusiones

7 Referencias



# Reconocimiento de emociones

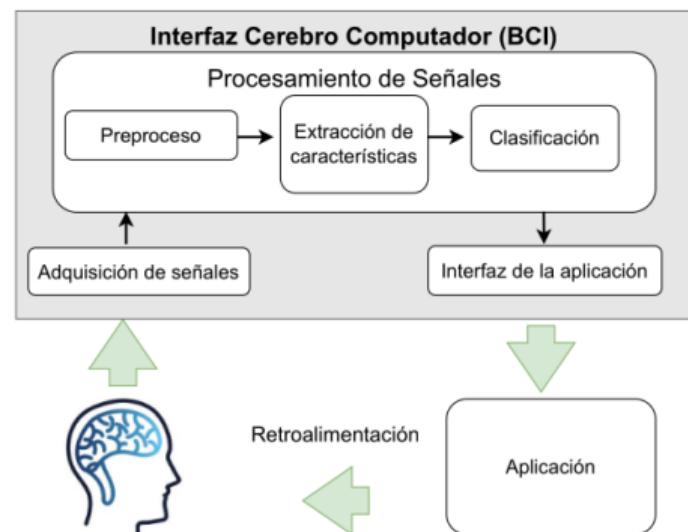
Sistemas informáticos con capacidad de procesar, reconocer y comprender con precisión la información emocional expresada por los seres humanos [Noroozi et al., 2021]





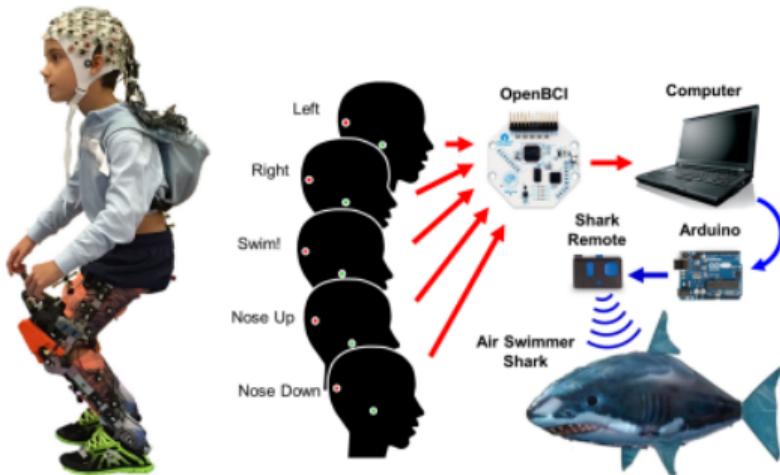
# BCI

Las Interfaces Cerebro Computador (BCI), establecen una conexión directa entre el cerebro humano y una computadora [Padfield et al., 2019]





# Aplicaciones de BCI

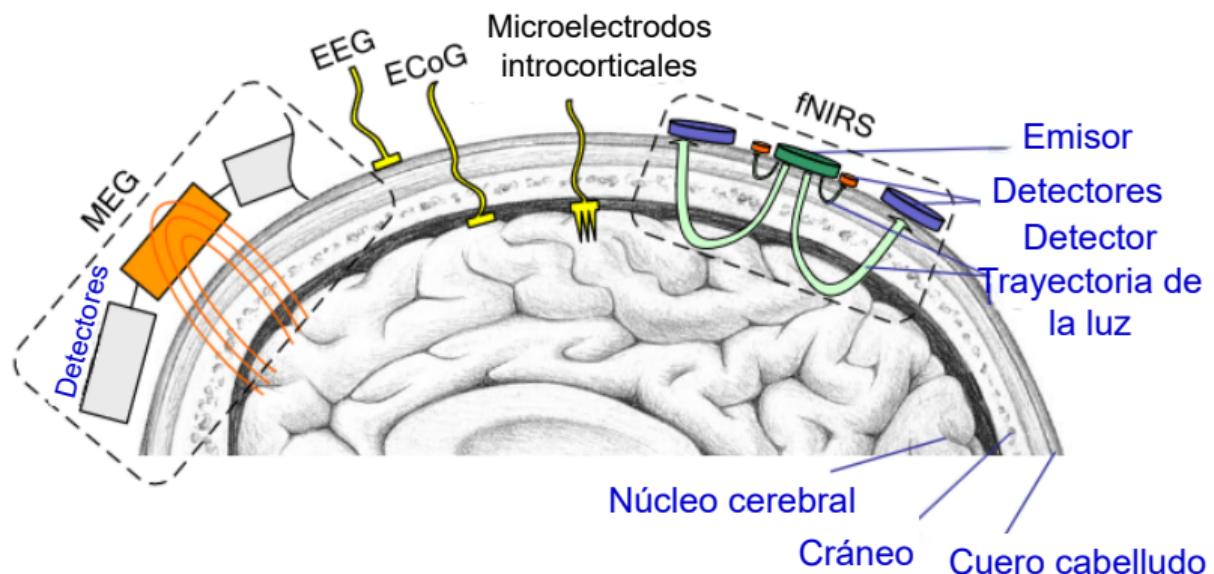


- Protocolos médicos [Choi et al., 2020]
- Diagnóstico [Fraiwan et al., 2021]
- Neurorrehabilitación [Padfield et al., 2019]
- Neuromarketing [Tremmel et al., 2019]
- Control de videojuegos [Padfield et al., 2019]
- Educación [Taherian and Davies, 2018]



# EEG

El EEG es el método más común en los sistemas BCI debido a su alta resolución temporal, costo relativamente bajo, alta portabilidad y bajos riesgos para los usuarios. [Miao et al., 2020]





# Contenido

1 Motivacion

2 Problema

3 Estado del arte

4 Objetivos

5 Experimentos

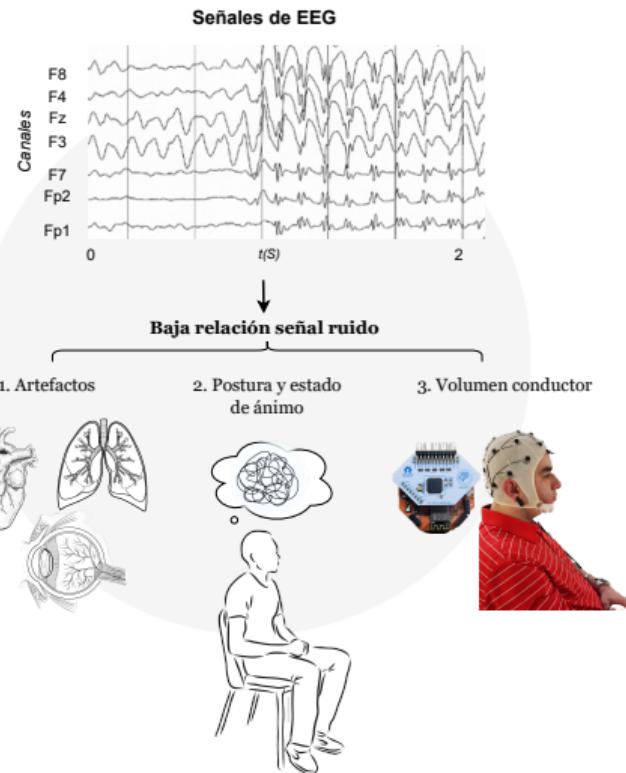
6 Conclusiones

7 Referencias



# Variabilidad inter sujeto

- Las diferencias individuales entre participantes generan patrones EEG únicos, complicando la creación de un modelo generalizable para todos los sujetos. [Jafari et al., 2023]
- La naturaleza no estacionaria de las señales EEG provoca cambios en las características a lo largo del tiempo, dificultando la consistencia del modelo. [Wriessnegger et al., 2020]





# Contenido

1 Motivacion

2 Problema

3 Estado del arte

4 Objetivos

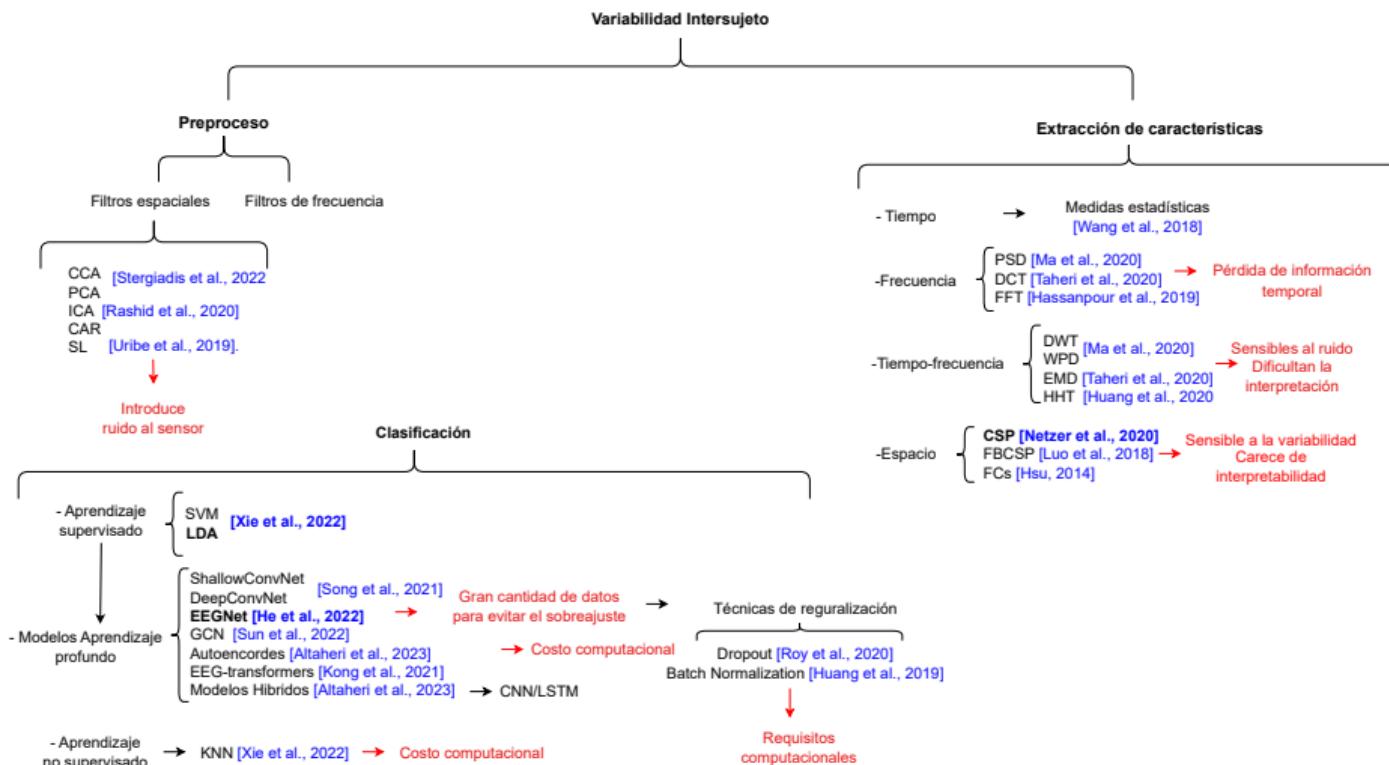
5 Experimentos

6 Conclusiones

7 Referencias



# Estado del arte





# Contenido

1 Motivacion

2 Problema

3 Estado del arte

4 Objetivos

5 Experimentos

6 Conclusiones

7 Referencias



# Objetivos

Desarrollar un sistema de reconocimiento de emociones basado en señales EEG que supere las limitaciones de la variabilidad ínter sujeto.

- Identificar y clasificar emociones en función de las señales EEG utilizando un modelo de red neuronal convolucional (EEGNet).
- Evaluar la precisión del modelo en diferentes ensayos y condiciones experimentales.
- Utilizar técnicas de visualización como GradCAM para interpretar las decisiones del modelo y comprender mejor la relación entre la actividad cerebral y las emociones.



# Contenido

1 Motivacion

2 Problema

3 Estado del arte

4 Objetivos

**5 Experimentos**

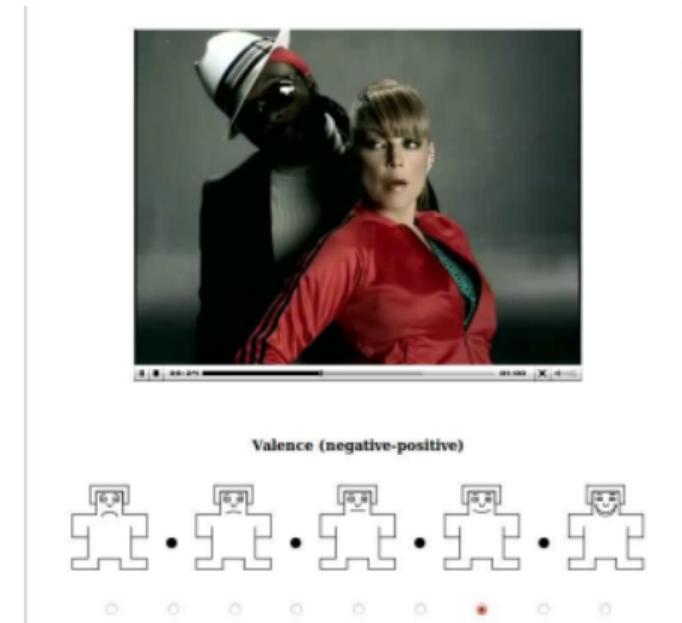
6 Conclusiones

7 Referencias



# Adquisición de Datos

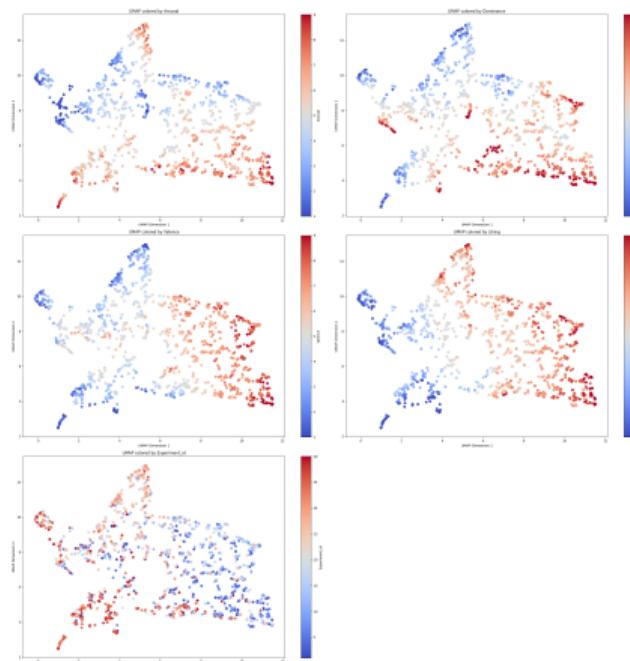
Se utilizaron señales EEG recolectadas durante la visualización de vídeos emocionales, que fueron clasificadas en términos de valencia y arousal. (DEAP dataset)





# Análisis de Dimensionalidad

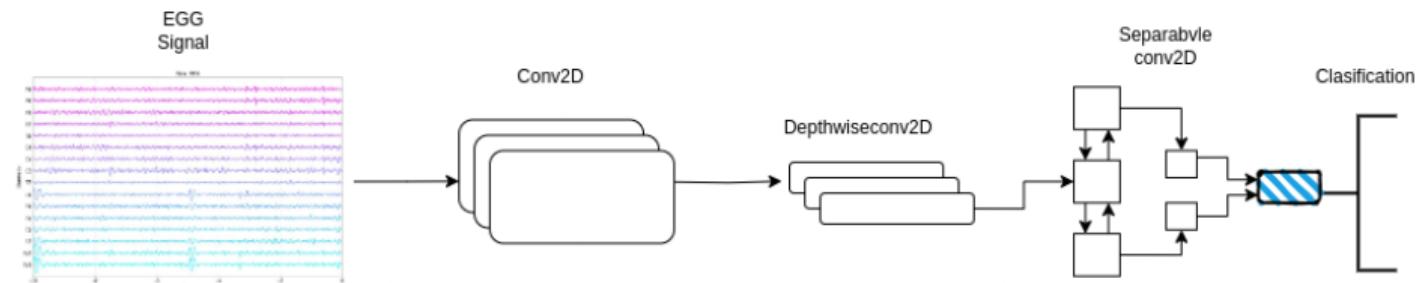
Se aplicó UMAP para la reducción de dimensionalidad y la visualización de la estructura subyacente de los datos.





# Modelo EEGNet

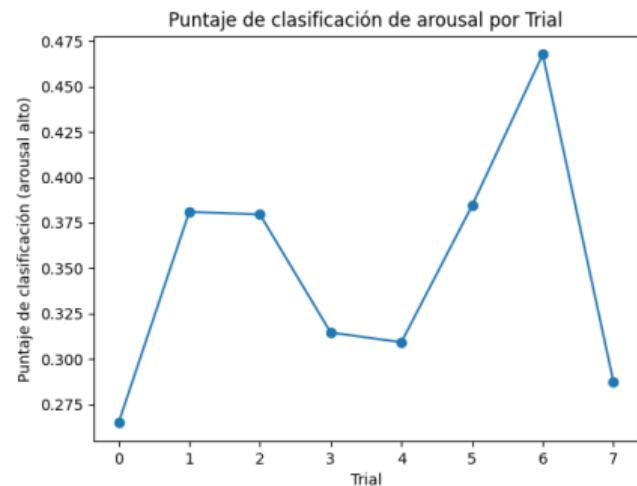
Se desarrolló un modelo de red neuronal convolucional para clasificar los niveles de arousal en las señales EEG.





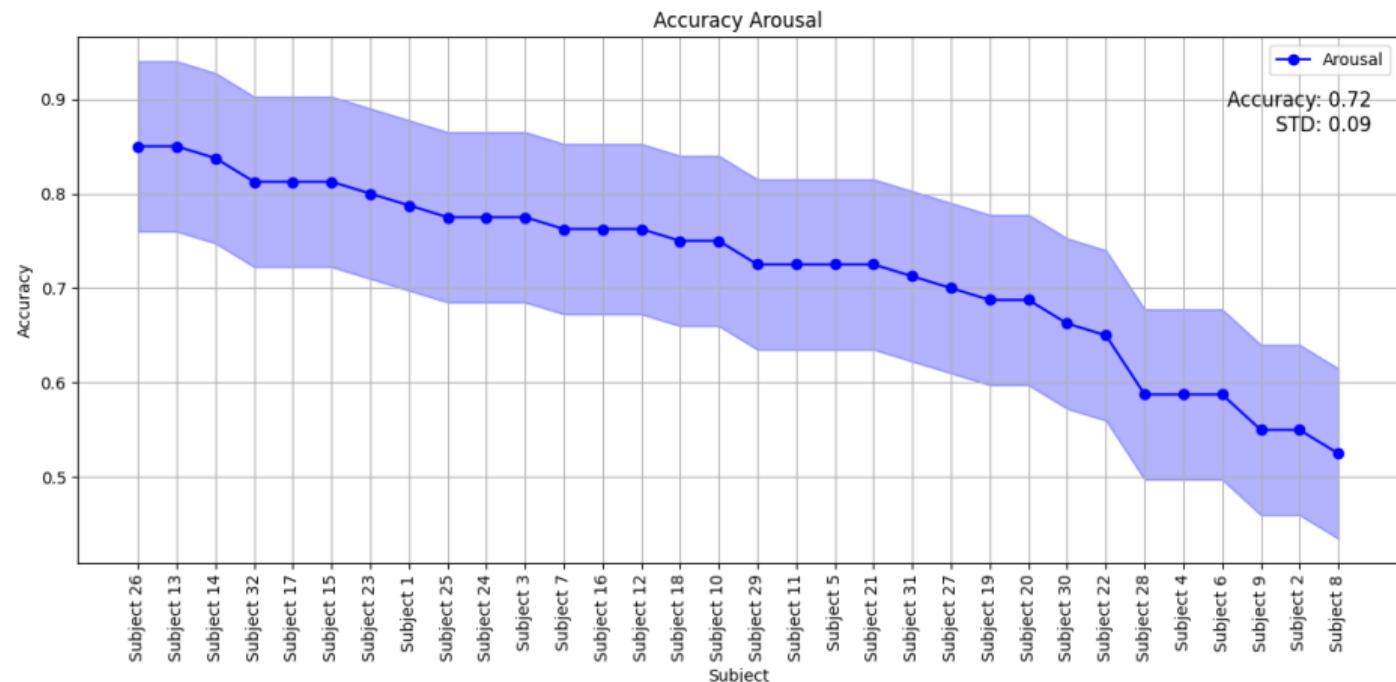
# Evaluación de Precisión

Se analizó la precisión del modelo en diferentes ensayos para identificar posibles debilidades y ajustar parámetros.





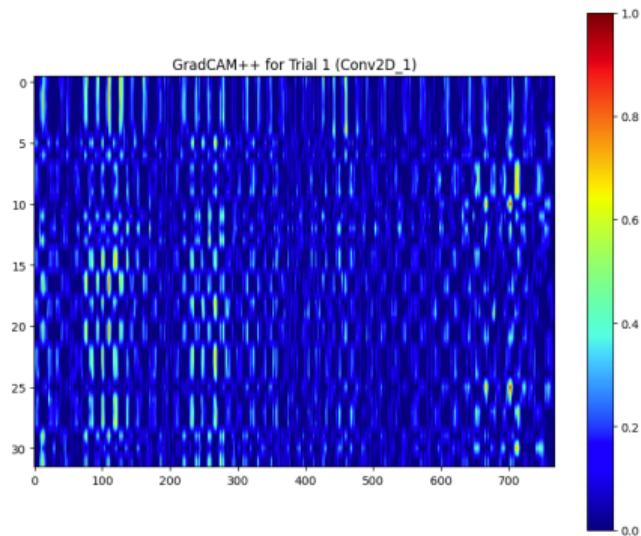
# Evaluación de Precisión





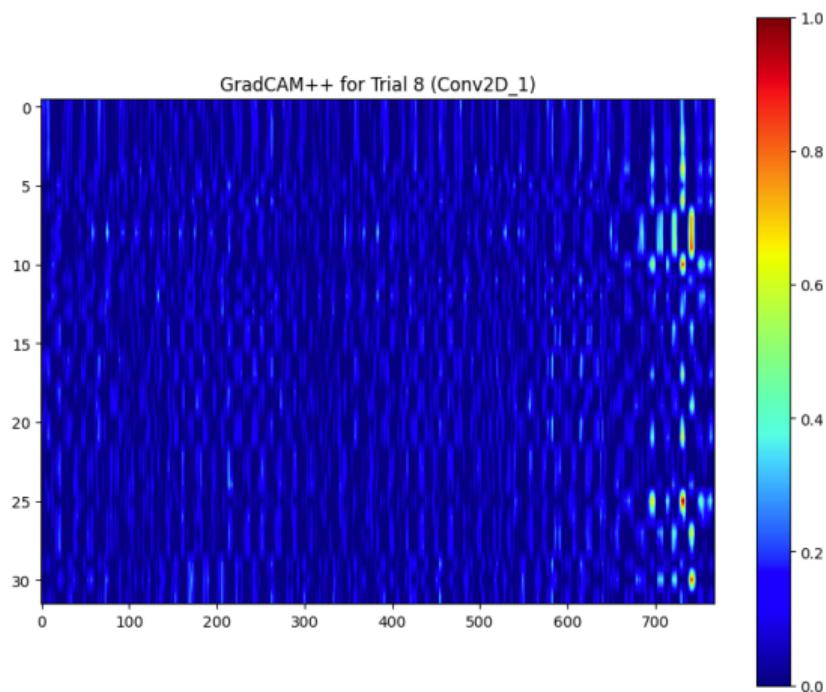
# Visualización de GradCAM

Se utilizaron mapas de activación para identificar las características más relevantes en las señales EEG que contribuyeron a la clasificación emocional.



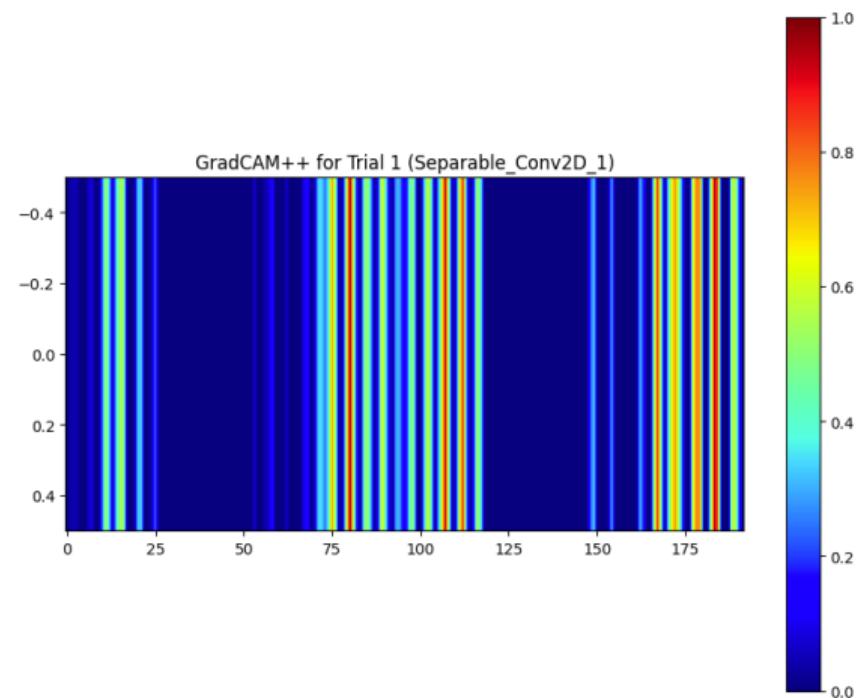


# Visualización de GradCAM



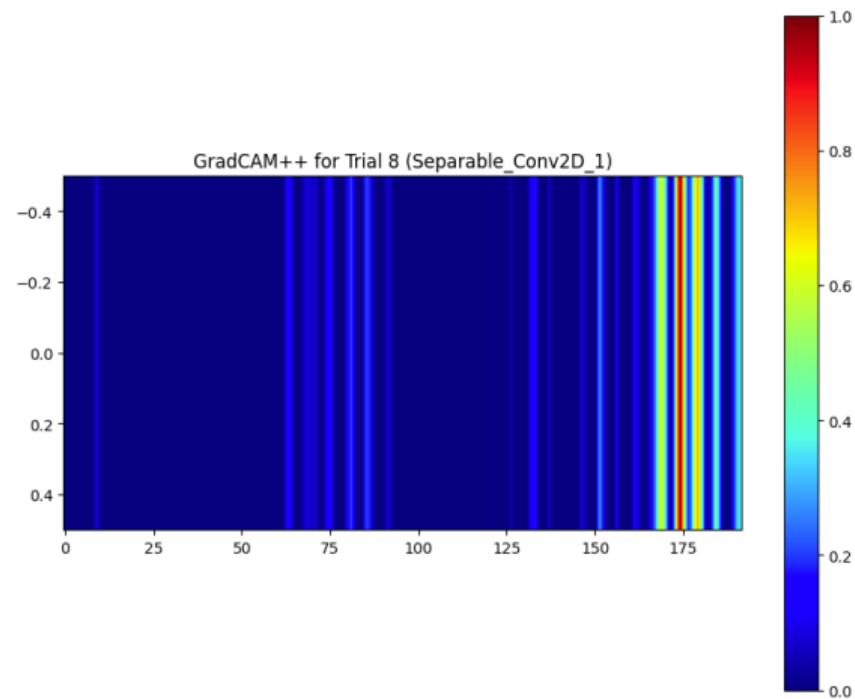


# Visualización de GradCAM





# Visualización de GradCAM





# Contenido

1 Motivacion

2 Problema

3 Estado del arte

4 Objetivos

5 Experimentos

6 Conclusiones

7 Referencias



# Conclusion

Los resultados obtenidos muestran que el modelo EEGNet es capaz de identificar y clasificar con éxito los niveles altos de arousal en las señales EEG, aunque se enfrenta a desafíos debido a la no estacionariedad inherente de las señales, lo que puede afectar la consistencia del rendimiento del modelo a lo largo del tiempo.



# Conclusion

La aplicación de UMAP facilitó la identificación de patrones en los datos, aunque la variabilidad entre sujetos agregó complejidad, ya que las diferencias individuales en los patrones EEG dificultan la generalización. La visualización de GradCAM proporcionó información valiosa sobre las características relevantes en las señales EEG.



# Contenido

1 Motivacion

2 Problema

3 Estado del arte

4 Objetivos

5 Experimentos

6 Conclusiones

7 Referencias



# References I



Choi, J., Kim, K. T., Jeong, J. H., Kim, L., Lee, S. J., and Kim, H. (2020).

Developing a motor imagery-based real-time asynchronous hybrid bci controller for a lower-limb exoskeleton.  
*Sensors*, 20(24):7309.



Fraiwan, M., Alafeef, M., and Almomani, F. (2021).

Gauging human visual interest using multiscale entropy analysis of eeg signals.  
*Journal of Ambient Intelligence and Humanized Computing*, 12(2):2435–2447.



Jafari, M., Shoeibi, A., Khodatars, M., Bagherzadeh, S., Shalbaf, A., García, D. L., Gorri, J. M., and Acharya, U. R. (2023).

Emotion recognition in eeg signals using deep learning methods: A review.  
*Computers in Biology and Medicine*, 165:107450.



Miao, M., Hu, W., Yin, H., and Zhang, K. (2020).

Spatial-frequency feature learning and classification of motor imagery eeg based on deep convolution neural network.  
*Computational and mathematical methods in medicine*, 2020.



Noroozi, F., Corneanu, C. A., Kamińska, D., Sapiński, T., Escalera, S., and Anbarjafari, G. (2021).

Survey on emotional body gesture recognition.  
*IEEE Transactions on Affective Computing*, 12(2):505–523.



Padfield, N., Zabalza, J., Zhao, H., Masero, V., and Ren, J. (2019).

Eeg-based brain-computer interfaces using motor-imagery: Techniques and challenges.  
*Sensors*, 19(6):1423.



# References II

 Taherian, S. and Davies, T. C. (2018).

Caregiver and special education staff perspectives of a commercial brain-computer interface as access technology: a qualitative study.  
*Brain-Computer Interfaces*, 5(2-3):73–87.

 Tremmel, C., Herff, C., Sato, T., Rechowicz, K., Yamani, Y., and Krusienski, D. J. (2019).

Estimating cognitive workload in an interactive virtual reality environment using eeg.  
*Frontiers in human neuroscience*, 13:401.

 Wriessnegger, S. C., Müller-Putz, G. R., Brunner, C., and Sburlea, A. I. (2020).

Inter-and intra-individual variability in brain oscillations during sports motor imagery.  
*Frontiers in human neuroscience*, 14:576241.